

heldout 基线的 10 个错误里，3 个是数据问题而非模型能力不足

若将 2 条疑似标签错误按「未决」处理：错误 10 $\rightarrow$ 8，敏感度上界 99.28%（官方分仍为 99.10%）

